

Description du dataset Pokémon

1. Introduction

Dans le cadre du module 165, nous avons choisi de travailler avec un dataset Open Data contenant des informations sur les Pokémon provenant du site kaggle.com.

Les Pokémon sont des créatures fictives issues de la franchise du même nom, très utilisée dans les jeux vidéo, les séries animées et les cartes à collectionner. Ce dataset permet d'analyser différentes caractéristiques de ces créatures, telles que leurs statistiques, leurs types et leurs générations.

Ce choix de données est pertinent car :

- Ce dataset contient un grand nombre d'éléments (>20 documents requis).
- Ces données sont variées et structurées.
- Il permet de réaliser des requêtes intéressantes et exploitables dans une application.

2. Source des données

Le dataset utilisé provient d'une source Open Data de kaggle.com :

- Lien : [⚡ Pokémon Complete Database \(2026\)](#)
- Fichier : pokemon_complete.csv
- Format : CSV converti en JSON pour MongoDB via un script Python.
- Contenu : 1350 Pokémon avec leurs caractéristiques

Le dataset a été légèrement modifié (réduction du nombre de lignes) afin de faciliter son exploitation dans le cadre du projet, le nombre de Pokémon est plafonné à 150.

3. Structure des données

Chaque document représente un Pokémon et contient plusieurs champs décrivant ses caractéristiques.

Exemple des champs principaux et leur description dans un document JSON :

```
_id: ObjectId('69f07809895a70a70bd24576'),
pokedex_number: 3,
name: 'Venusaur',
type_1: 'Grass',
type_2: 'Poison',
hp: 80,
attack: 82,
defense: 83,
sp_attack: 100,
sp_defense: 100,
speed: 80,
base_stat_total: 525,
height_m: 2,
weight_kg: 100,
base_experience: 236,
abilities: 'overgrow|chlorophyll',
hidden_ability: 'chlorophyll',
generation: 'gen-i',
is_legendary: false,
is_mythical: false,
is_baby: false,
color: 'green',
shape: 'quadruped',
egg_groups: 'monster|plant',
habitat: 'grassland',
growth_rate: 'medium-slow',
capture_rate: 45,
base_happiness: 70,
genus: 'Seed Pokémon',
evolution_chain_id: 1,
flavor_text: 'The plant blooms when it is absorbing solar energy. It stays on the move to seek sunlight.',
sprite_url: 'https://raw.githubusercontent.com/PokeAPI/sprites/master/sprites/pokemon/3.png'
```

4. Préparation des données

Les étapes suivantes ont été réalisées :

1. Conversion du fichier CSV en JSON via un script python.
2. Réduction du nombre de documents pour simplifier les tests.
3. Importation dans MongoDB dans la collection open_data.

5. Utilisation prévue des données

Les données Pokémon seront utilisées pour :

5.1 Analyse des caractéristiques

- Trouver les Pokémon les plus puissants
- Afficher les statistiques (attaque, défense, vitesse)

5.2 Requêtes MongoDB

- Afficher les noms des bases de données disponibles dans le serveur
- Afficher les noms des collections dans my_data.

- Compter le nombre des documents de chaque collection
- Filtrer les Pokémon par type
- Rechercher les Pokémon d'une génération spécifique
- Trier les Pokémon selon leurs statistiques

5.3 Application Python

Une application sera développée pour afficher les données avec :

- Une liste des Pokémon
- Une recherche par type ou nom
- Un classement (top Pokémon selon statistiques)

6. Conclusion

Le dataset Pokémon est adapté à ce labo car il permet d'avoir, en premier lieu, une structure claire et exploitable, en deuxième lieu, une grande variété de données et en dernier lieu, des possibilités d'analyses intéressantes. Il permet également de répondre aux objectifs du module concernant la gestion de base de données MongoDB, l'interrogation avec mongosh, l'optimisation avec index ainsi que l'exploitation via une application.